

```

In [24]: print('研究问题: ','有淋巴结转移和无淋巴结转移的乳腺癌患者, 其临床病理特征是否存在
print('需要分析的变量: ')
import pandas as pd
table1=pd.DataFrame({
    'variable':['Age','Tumor_Size','Ki67','ER','PR','HER2'],
    '中文':['年龄','肿瘤大小','Ki67表达水平','ER状态','PR状态','HER状态'],
    '变量类型':['连续变量','连续变量','连续变量','二分类变量','二分类变量','二分类变量'])
print(table1)
import pandas as pd
df=pd.read_csv('breast_cancer_clinical3.csv')
print('读取breast_cancer_clinical3.csv成功')
print('Age:',df[['Age']].describe())
print('Tumor_Size:',df[['Tumor_Size']].describe())
print('Ki67:',df[['Ki67']].describe())
print()
print('对连续变量进行正态性检验: ')
import scipy
from scipy.stats import shapiro
stat,p=shapiro(df['Age'])
print('Age的p值:',p)
stat,p=shapiro(df['Tumor_Size'])
print('Tumor_Size的p值:',p)
stat,p=shapiro(df['Ki67'])
print('Ki67的p值:',p)
print('结果分析如下: ')
print('Age和Tumor_Size的p值均大于0.05, 因此没有理由认为Age和Tumor_Size不符合方差齐性')
print('Ki67的p值小于0.05, 因此Ki67不符合方差齐性')
print('Age的直方图: ')
import matplotlib.pyplot as plt
plt.hist(df['Age'],bins=10)
plt.xlabel('Age')
plt.ylabel('Frequency')
plt.show()
print('Age的Q-Q图:')
import scipy.stats as stats
import matplotlib.pyplot as plt
stats.probplot(df['Tumor_Size'],dist='norm',plot=plt)
plt.show()
print('Tumor_Size的直方图: ')
plt.hist(df['Tumor_Size'],bins=10)
plt.xlabel('Tumor_Size')
plt.ylabel('Frequency')
plt.show()
print('Tumor_Size的Q-Q图: ')
stats.probplot(df['Tumor_Size'],dist='norm',plot=plt)
plt.show()
print('-----')
print('Age和Tumor_Size的t检验:')
LN0=df[df['Lymph_Node']==0]
LN1=df[df['Lymph_Node']==1]
from scipy.stats import ttest_ind
t,p=ttest_ind(LN0['Age'],LN1['Age'],equal_var=False)
print('Age的t值:',t)
print('Age的p值:',p)
t,p=ttest_ind(LN0['Tumor_Size'],LN1['Tumor_Size'],equal_var=False)
print('Tumor_Size的t值:',t)
print('Tumor_Size的p值:',p)

```

```

print('因为Age的p值<0.05,因此两组的年龄差异存在统计学意义。')
print('因为Tumor_Size的p值<0.05, 因此两组的Tumor_Size差异存在统计学意义。')
print('-----')
print('Ki67的Mann_Whitney_U检验: ')
from scipy.stats import mannwhitneyu
u,p=mannwhitneyu(LN0['Ki67'],LN1['Ki67'],alternative='two-sided')
print('Ki67的u值: ',u)
print('Ki67的p值: ',p)
print('因为Ki67的p值>0.05,因此两组的Ki67水平未存在统计学差异。')
print('-----')
table5=pd.DataFrame({
    'Variable':['Age','Tumor_Size','Ki67'],
    'Shapiro P':[0.979,0.916,0.002],
    'Distribution':['Normal','Normal','Non-Normal'],
    'Mean±SD/Median(Q1,Q3)':['51.95±8.67','3.20±1.02','30(15,70)'],
    'Analysis':['t-test','t-test','u-test'],
    'P value':[0.001,0.0007,0.4]
})
print('连续变量统计表:')
print(table5)
table5.to_excel('Table 1. Characteristics of Breast Cancer Patients.xlsx')
print('-----')
print('分类变量的chi square检验')
from scipy.stats import chi2_contingency
table2=pd.crosstab(df['ER'],df['Lymph_Node'])
print(table2)
chi2,p,dof,expected=chi2_contingency(table2)
print('ERvsLN的p值:',p)
print('ERvsLN的expected:',expected)
table3=pd.crosstab(df['PR'],df['Lymph_Node'])
print(table3)
chi2,p,dof,expected=chi2_contingency(table3)
print('PRvsLN的p值:',p)
print('PRvsLN的expected:',expected)
table4=pd.crosstab(df['HER2'],df['Lymph_Node'])
print(table4)
chi2,p,dof,expected=chi2_contingency(table4)
print('HER2vsLN的p值: ',p)
print('HER2vsLN的expected:',expected)
print('统计结果如下: ')
print('ER和HER2的表达状态与淋巴结转移未发现显著关联。')
print('PR的表达状态与淋巴结转移存在统计学关联。')
print('(说明: 1.expected的值不满足>5超过80%。2.样本量太少 所以最好进行fisher检测)')
print('-----')
print('分类变量的fisher检测: ')
from scipy.stats import fisher_exact
oddsratio,p=fisher_exact(table2)
print('ERvsLN的OR值: ',oddsratio)
print('ERvsLN的p值: ',p)
oddsratio,p=fisher_exact(table3)
print('PRvsLN的OR值: ',oddsratio)
print('PRvsLN的p值: ',p)
oddsratio,p=fisher_exact(table4)
print('HER2vsLN的OR值: ',oddsratio)
print('HER2vsLN的p值: ',p)
print('ER和HER2的表达状态与淋巴结转移未发现显著关联。')
print('PR的表达状态与淋巴结转移存在统计学关联。')
print('-----')
table6=pd.DataFrame({
    'Variable':['ER','PR','HER2'],

```

```

'Expected是否合适':['否','否','否'],
'最终方法':['Fisher','Fisher','Fisher'],
'P value':[0.07,0.02,0.07]
})
print('分类变量统计表: ')
print(table6)
table6.to_excel('Table 2. Characteristics of Breast Cancer Patients.xlsx')

```

研究问题： 有淋巴结转移和无淋巴结转移的乳腺癌患者，其临床病理特征是否存在差异？
需要分析的变量：

	variable	中文	变量类型
0	Age	年龄	连续变量
1	Tumor_Size	肿瘤大小	连续变量
2	Ki67	Ki67表达水平	连续变量
3	ER	ER状态	二分类变量
4	PR	PR状态	二分类变量
5	HER2	HER状态	二分类变量

读取breast_cancer_clinical3.csv成功

Age: Age

```

count 20.000000
mean 51.950000
std 8.666177
min 36.000000
25% 46.500000
50% 51.500000
75% 58.250000
max 67.000000

```

Tumor_Size: Tumor_Size

```

count 20.00000
mean 3.19500
std 1.02108
min 1.50000
25% 2.45000
50% 3.10000
75% 3.85000
max 5.10000

```

Ki67: count 20.000000

```

mean 41.250000
std 31.450671
min 10.000000
25% 15.000000
50% 30.000000
75% 70.000000
max 95.000000

```

Name: Ki67, dtype: float64

对连续变量进行正态性检验：

Age的p值：0.9788032525063932

Tumor_Size的p值：0.9162922826518878


Ki67的p值：0.002156689932776424

结果分析如下：


Age和Tumor_Size的p值均大于0.05，因此没有理由认为Age和Tumor_Size不符合方差齐性。

Ki67的p值小于0.05，因此Ki67不符合方差齐性


Age的直方图：




Age的Q-Q图：



Tumor_Size的直方图：



Tumor_Size的Q-Q图:



Age和Tumor_Size的t检验:

Age的t值: -3.7742011369486237

Age的p值: 0.0017755616146161615

Tumor_Size的t值: -4.149738068893663

Tumor_Size的p值: 0.0007047471803138009

因为Age的p值<0.05,因此两组的年龄差异存在统计学意义。

因为Tumor_Size的p值<0.05,因此两组的Tumor_Size差异存在统计学意义。

Ki67的Mann_Whitney_U检验:

Ki67的u值: 38.5

Ki67的p值: 0.42151799737413176

因为Ki67的p值>0.05,因此两组的Ki67水平未存在统计学差异。

连续变量统计表:

	Variable	Shapiro P	Distribution	Mean±SD/Median(Q1,Q3)	Analysis	P value
0	Age	0.979	Normal	51.95±8.67	t-test	0.0010
1	Tumor_Size	0.916	Normal	3.20±1.02	t-test	0.0007
2	Ki67	0.002	Non-Normal	30(15,70)	u-test	0.4000

分类变量的chi square检验

Lymph_Node 0 1

ER

0 1 6

1 8 5

ERvsLN的p值: 0.11997996734471256

ERvsLN的expected: [[3.15 3.85]

[5.85 7.15]]

Lymph_Node 0 1

PR

0 2 9

1 7 2

PRvsLN的p值: 0.02686447196134021

PRvsLN的expected: [[4.95 6.05]

[4.05 4.95]]

Lymph_Node 0 1

HER2

0 7 3

1 2 8

HER2vsLN的p值: 0.07219819770165818

HER2vsLN的expected: [[4.5 5.5]

[4.5 5.5]]

统计结果如下:

ER和HER2的表达状态与淋巴结转移未发现显著关联。

PR的表达状态与淋巴结转移存在统计学关联。

(说明: 1.expected的值不满足>5超过80%。2.样本量太少 所以最好进行fisher检测)

分类变量的fisher检测:

ERvsLN的OR值: 0.10416666666666667

ERvsLN的p值: 0.07027863777089784

PRvsLN的OR值: 0.06349206349206349

PRvsLN的p值: 0.02155275065491784

HER2vsLN的OR值: 9.333333333333334

HER2vsLN的p值: 0.06977851869492736

ER和HER2的表达状态与淋巴结转移未发现显著关联。

PR的表达状态与淋巴结转移存在统计学关联。

分类变量统计表:

	Variable	Expected是否合适	最终方法	P value
0	ER	否	Fisher	0.07

1	PR	否	Fisher	0.02
2	HER2	否	Fisher	0.07

In []: